

# Trabajo Práctico Final

# Laboratorio de Datos

Grupo 3  
Manuela Cerdeiro  
Martín Estévez

# Introducción

# La Ilusión de los Mapas


Cuando uno observa un mapa político de cualquier país, en particular en este caso la Argentina, todo parece estar distribuido de manera más o menos equitativa.

Una provincia aquí, otra provincia allá. Aún viendo los departamentos y partidos, cualquier persona que lo mira sin pensarlo mucho podría verse tentada a pensar que las divisiones siguen un criterio balanceado.




# La Ilusión de los Mapas

La realidad, sin embargo, es otra. Por diversas razones históricas y económicas, nuestro país está entre los más asimétricos en lo que a densidad de población se refiere. Más allá de lo esperado, alrededor del 30% de la población se concentra en un solo centro urbano; otro 30% en un radio de no más de 500 km alrededor de éste. Y con la población concentrada, es esperable que el resto del país se vea olvidado en muchas cuestiones de infraestructura.



# Las Luces del Estadio

Basta con ver un mapa nocturno. La Cuenca del Plata y las capitales provinciales concentran la mayor parte de la población y por ende de la infraestructura. Además, suelen ser los centros de cultura, educación y, en concreto para este trabajo, salud de muchas provincias.

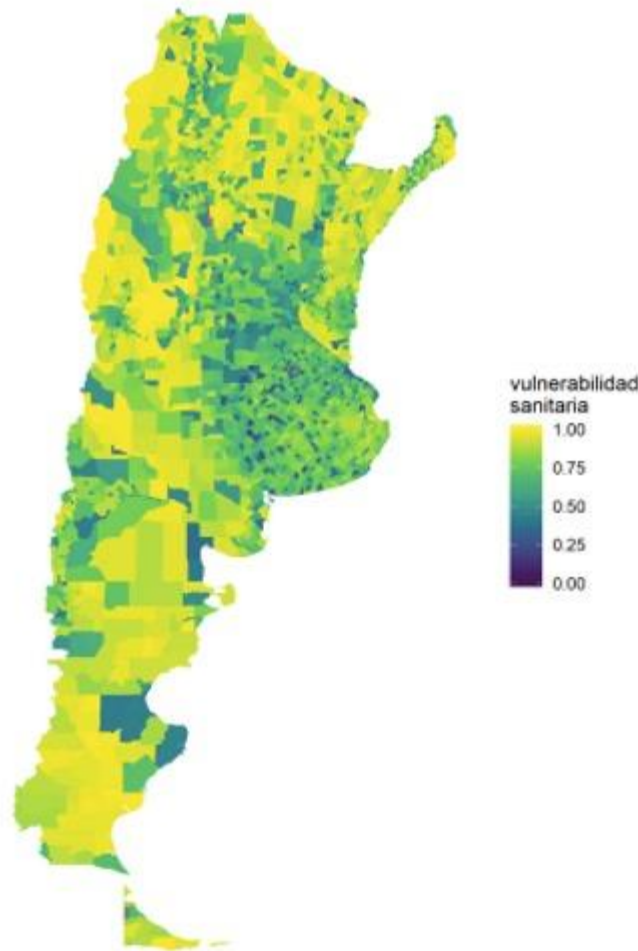


# La Cuestión de la Salud

Sobre esto último, utilizaremos los datos de la Fundación Bunge y Born y del INDEC. En concreto, la fundación elabora un “Índice de Vulnerabilidad Sanitaria” (IVS), que representa la vulnerabilidad de una población en un área censal dada.

En el informe de donde se sacó este mapa señalan como notable la disparidad que hay entre la región central del país y el resto de las zonas periféricas. Sin embargo, nos interesaba poner la lupa en un punto en concreto.

Notamos que muchas provincias del a veces llamado “interior profundo” tienen sus capitales muy alejadas del resto de la provincia y mucha población concentrada en ellas. Nuestra hipótesis inicial fue, entonces, que **la lejanía de una ciudad a su capital provincial afecta negativamente su IVS.**







## Diferencias entre Jurisdicciones

Hay algunos casos, como los de la imagen, que son extremos y que pueden entenderse si se comparan las situaciones de las provincias en general. Sin embargo, usando a Chaco como ejemplo, se puede ver claramente que los centros urbanos tienen un mejor puntaje que las zonas rurales y en particular su capital.


Nos pareció interesante entonces, estudiar cada provincia por separado y comparar los resultados tratando de ver cuánto incidía la distancia comparativamente, no en términos absolutos.



CABA



Chaco  
(en rojo Resistencia)



# Hipótesis Inicial

Nuestra hipótesis inicial, como se mencionó, es que la distancia a la capital es de hecho un factor que está correlacionado positivamente con el empeoramiento de la calidad de vida en lo que a salud respecta.

Además, vamos a analizar algunos otros factores como la distancia a hospitales de alta complejidad y a centros universitarios a modo exploratorio para testear algunos otros factores y además nos interesa ver *qué tanto* las capitales actuales se alejan de un teórica “ideal” y si ésto es algo notorio.



# Desarrollo

# Obtención de la Información

- Datos censales INDEC + CEUR
- IVS Bunge y Born.
- Distancias API de Google Maps.
- Wikipedia



# Distancia Geométrica vs. Distancia en Ruta vs. Tiempo de Viaje

## ¿Qué usar para medir la distancia entre capitales?





## Distancia Geométrica vs. Distancia en Ruta vs. Tiempo de Viaje

¿Qué usar para medir la distancia entre capitales?



# Procedimiento

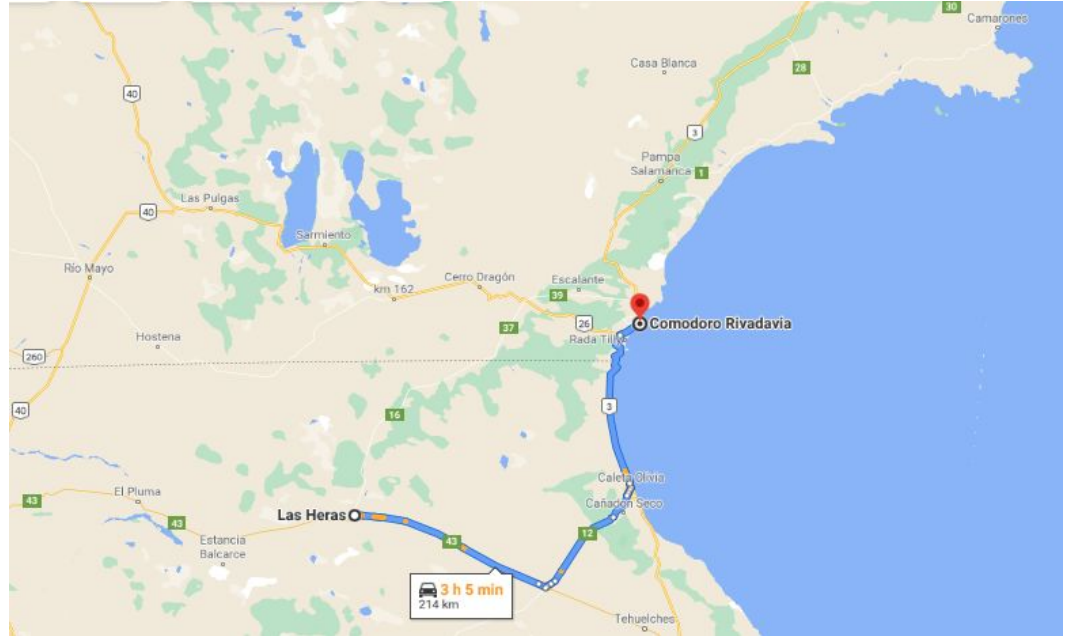
- Analizar para cada provincia por separado las distancias entre poblaciones y la capital.
- Contrastar valores y ver qué tanto la capital se aleja de las otras ciudades





# Algunos Problemas

Al dividir todo por provincias, no nos permitimos considerar la distancia a centros regionales que pueden llegar a ser más relevantes que una capital pero están fuera de los límites de la provincia.



# Desarrollo: Obtención de la Información

- Armado de diccionario  

```
{provincia: capital}
```

 guardado en formato .json
- Armado de lista de diccionarios con:  

```
["departamento": " ",  
"provincia": " ",  
"cabecera": " ",  
"poblacion_dep": " ",  
"tipo_ciudad": " "}
```

```
1 {  
2 {  
3   "departamento": "12 de Octubre",  
4   "provincia": "Chaco",  
5   "cabecera": "General Pinedo",  
6   "poblacion_dep": "22225",  
7   "tipo_ciudad": "Ciudad"  
8 },  
9 {  
10  "departamento": "25 de Mayo",  
11  "provincia": "Chaco",  
12  "cabecera": "Machagai",  
13  "poblacion_dep": "29315",  
14  "tipo_ciudad": "Ciudad"  
15 },  
16 {  
17  "departamento": "25 de Mayo",  
18  "provincia": "Misiones",  
19  "cabecera": "25 de Mayo",  
20  "poblacion_dep": "27754",  
21  "tipo_ciudad": "Ciudad"  
22 },  
23 {  
24  "departamento": "9 de Julio",  
25  "provincia": "Chaco",  
26  "cabecera": "Las Brenas",  
27  "poblacion_dep": "30153",  
28  "tipo_ciudad": "Ciudad"  
29 },  
30 {  
31  "departamento": "9 de Julio",  
32  "provincia": "Santa Fe",  
33  "cabecera": "Tostado",  
34  "poblacion_dep": "29810",  
35  "tipo_ciudad": "Ciudad"  
36 },  
}
```

	A	B	C	D	E
1		trayecto		tiempo	valor
2	Rio Negro	Viedma-Choeles Choeles		332 km	332017
3				duracion 3 hours 36 mins	12979
4		Viedma-San Carlos de Bariloche		825 km	824834
5				duracion 9 hours 36 mins	34956
6		Viedma-General Conesa		157 km	156990
7				duracion 1 hour 43 mins	6508
8		Viedma-El Cuy		600 km	600440
9				duracion 6 hours 54 mins	24847
10		Viedma-General Roca		512 km	512254
11				duracion 5 hours 47 mins	20844
12		Viedma-Sierra Colorado		492 km	491890
13				duracion 4 hours 43 mins	16976
14		Viedma-Rosquitos		762 km	762010
15				duracion 9 hours 58 mins	35668
16		Viedma-Rio Colorado		306 km	305903
17				duracion 3 hours 24 mins	12237
18		Viedma-Picavetou		765 km	764750
19				duracion 9 hours 40 mins	31195
20		Viedma-San Antonio Oeste		180 km	180497
21				duracion 2 hours 4 mins	7433
22		Viedma-Valcheta		282 km	285011
23				duracion 3 hours 9 mins	11113
24		Viedma-Merquichao		550 km	549506
25				duracion 5 hours 48 mins	20890
26	Catamarca	San Fernando del Valle de Catamarca-La Puente		42.6 km	42584
27				duracion 52 mins	3149
28		San Fernando del Valle de Catamarca-Ancasti		89.2 km	89182
29				duracion 1 hour 41 mins	6051
30		San Fernando del Valle de Catamarca-Andagala		247 km	246978
31				duracion 2 hours 59 mins	10718
32		San Fernando del Valle de Catamarca-Ancasti de la		551 km	551010
33				duracion 9 hours 36 mins	30956
34		San Fernando del Valle de Catamarca-Belen		293 km	292933
35				duracion 3 hours 36 mins	12887
36		San Fernando del Valle de Catamarca-Huabara		37.6 km	37602
37				duracion 34 mins	2082
38		San Fernando del Valle de Catamarca-El Alto		77.5 km	77471

```
1 {  
2 "Rio Negro" : "Viedma",  
3 "Catamarca" : "San Fernando del Valle de Catamarca",  
4 "Cordoba" : "Cordoba",  
5 "Corrientes" : "Corrientes",  
6 "La Pampa" : "Santa Rosa",  
7 "La Rioja" : "La Rioja",  
8 "Mendoza" : "Mendoza",  
9 "Misiones" : "Posadas",  
10 "Salta" : "Salta",  
11 "San Juan" : "San Juan",  
12 "Santiago del Estero" : "Santiago del Estero",  
13 "Tucuman" : "San Miguel de Tucuman",  
14 "Neuquen" : "Neuquen",  
15 "Formosa" : "Formosa",  
16 "Santa Cruz" : "Rio Gallegos",  
17 "San Luis" : "San Luis",  
18 "Santa Fe" : "Santa Fe de la Vera Cruz",  
19 "Buenos Aires" : "La Plata",  
20 "Entre Rios" : "Parana",  
21 "Chubut" : "Rawson",  
22 "Chaco" : "Resistencia",  
23 "Jujuy" : "San Pedro de Jujuy",  
24 "Tierra del Fuego, Antartida e Islas del Atlantico Sur" : "Ushuaia"  
25 }  
26 }
```



# Desarrollo: Obtención de la Información

Con estos datos hicimos el primer intento. Hubo algunos problemas técnicos ya que al usar los nombres de las ciudades google tendía a confundirse.

Además, mucha información no estaba disponible con ese nivel de granularidad por lo que cambiamos el set. Nos fue útil para algunas cosas que mostraremos al final.

```
1 import json
2 import urllib.request
3
4
5
6
7
8
9 API_key = "AIzaSyB67G6R2kYv0"
10 file_departamentos = open("departamentos_sin_acentos.json", "r")
11 departamentos = json.loads(file_departamentos.read())
12 file_capitales = open("capitales.json", "r")
13 capitales = json.loads(file_capitales.read())
14
15 #departamentos = array con diccionarios que contiene datos de los departamentos
16 #capitales = diccionario con provincias como keys y capitales de las mismas como valores
17 distancias = {}
18 provincias = capitales.keys()
19 for cap in provincias:
20     distancias[cap] = []
21
22 for dep in departamentos:
23     if dep["tipo_ciudad"] == "Ciudad":
24         capital = capitales[dep["provincia"]].replace(" ", "_")
25         ciudad = dep["cabecera"].replace(" ", "_")
26         provincia = dep["provincia"].replace(" ", "_")
27         url = "https://maps.googleapis.com/maps/api/distancematrix/json?origins=" + ciudad + "&destinations=" + capital + "&key=" + API_key
28         dato_de_google = urllib.request.urlopen(url).read()
29         datos_json = json.loads(dato_de_google)
30         print(datos_json)
31         data = datos_json["rows"][0]["elements"][0]
32         ciudades = capital + "-" + ciudad
33
34
35
36
37
38
39
40
41 file = open("distancias.json", "w")
42 file.write(json.dumps(distancias))
43 file.close()
```

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	
1	Rio Negro	Ciudad	Rio Negro	distancia	Catamarca	Ciudad	Catamarca	distancia	Catamarca	tiempo	Cordoba	Ciudad	Cordoba	distancia	Cordoba	tiempo
2	Viedma	19499	19499	477296.25	477296.25	La_Puerta	10770.8	10770.8	199846.666	199846.67	San_Austin	9225.88	9225.88	203264.4	203264.4	
3	Choele_Che	16942.5833	16942.583	399289.916	399289.92	Ancastr	12223.8666	12223.867	219658.8	219658.8	Cordoba	8220.6	8220.6	169299.2	169299.2	
4	San_Carlos	21486.6666	21486.667	508162.916	508162.92	Andagasta	12410.8666	12410.867	256819.249	256819.25	Jesus_Maria	8440.08	8440.08	190883.12	190883.12	
5	General_Con	15888.1666	15888.167	380451.333	380451.33	Antofagasta	29873.2	29873.2	520282.733	520282.73	Cruz_del_Sur	12993.56	12993.56	22881.2	22881.2	
6	R_Cuy	16908.0833	16908.083	365774.416	365774.42	Belen	13414	13414	286002.466	286002.47	Villa_Huidob	19331.2	19331.2	453106	453106	
7	General_Roc	17269.9166	17269.917	386389.666	386389.67	Huillapima	8930.7333	8930.733	184350.2	184350.2	Villa_Maria	9917.04	9917.04	218284.88	218284.88	
8	San_Fernando	15588.6666	15588.667	506444.916	506444.92	R_Ato	121386.6666	121386.667	203117.2	203117.2	La_Carlista	13354.28	13354.28	288683.32	288683.32	
9	Rio_Colador	19300.5833	19300.583	459451.833	459451.83	Fray_Mamerto	10071.6666	10071.667	184483.533	184483.53	Marcos_Juar	13331.28	13331.28	318148.76	318148.76	
10	Pitaniyue	20763.5	20763.5	474554.333	474554.33	Recreo	12896.2666	12896.267	276612.6	276612.6	San_Carlos	12352.08	12352.08	265367.04	265367.04	
11	San_Antonio	14009.8333	14009.833	345052.416	345052.42	La_Merced	9428.0666	9428.067	190776.866	190776.87	Salsacate	12187.68	12187.68	263603.36	263603.36	
12	Yacheta	13960.6666	13960.667	318080.916	318080.92	Sejuli	11170.7333	11170.733	232796.2	232796.2	Laboulaye	16260.24	16260.24	369127.72	369127.72	
13	Maquinichao	14671.25	14671.25	339862.5	339862.5	Santa_Maria	17149.1333	17149.133	315618.866	315618.87	Cosquín	9310.84	9310.84	197482.52	197482.52	
14	Berardo_de	11005.5333	11005.533	222175.4	222175.4	Rio_Cuarto	12082.36	12082.36	264946.32	264946.32	San_Francisco	13940.4	13940.4	302501.04	302501.04	
15	Tinogasta	14537.9333	14537.933	308579.2	308579.2	San_Rosa	9787.96	9787.96	217446.8	217446.8	San_Francisco	13940.4	13940.4	302501.04	302501.04	
16	San_Nicolas	8679.3333	8679.333	171019.533	171019.53	Villa_del_Rio	9281.68	9281.68	199813.6	199813.6	Villa_Cura	11812.6	11812.6	248193.32	248193.32	
17		13610.667	13610.667	306274.50	306274.50	San_Juan	8679.3333	8679.333	171019.533	171019.53	Villa_de_Ma	11822.2	11822.2	247261.64	247261.64	
18											Villa_del_Rio	9281.68	9281.68	199813.6	199813.6	
19											Villa_Cura	11812.6	11812.6	248193.32	248193.32	
20											Villa_Dolore	13330.24	13330.24	271041.52	271041.52	
21											San_Francisco	13949.4	13949.4	302501.04	302501.04	
22											Alta_Gracia	8367.96	8367.96	179548.48	179548.48	
23											San_Francisco	12611.4	12611.4	269360.84	269360.84	
24											Olivo	9051.64	9051.64	198228.04	198228.04	
25											Villa_de_Tor	9069.6	9069.6	204922.32	204922.32	
26											Villa_Tulum	10323.24	10323.24	225885.16	225885.16	
27											Bell_Villa	11361.08	11361.08	265776.52	265776.52	
28																
29																
30																
31																

# Desarrollo: Obtención de la Información

Luego juntamos los datos de las fuentes utilizando (de Pandas).

- df con aglomerados y sus centroides (en lat-lon)
- df con info de qué radios censales pertenecen a cada aglomerado
- df con info demográfica por cada radio censal
- df con info de ivs por radio censal
- diccionario de capitales de provincia

# Desarrollo: Obtención de la Información

Juntamos todo  
en un  
data frame

seleccionamos  
aglomerados con al  
menos  
4000 personas

data_aglomerados - DataFrame												
Index	NOMBRE	LAT	LON	ES_CAPITAL	CANT_RADIOS	IVS_MEDIA	IVS_DESVIO	PROVINCIA	cant_personas	prop_infantes	prop_adultos	prop_m...
1	Gran Buenos...	-34.648	-58.567	0	13244	0.343173	0.21726	Buenos Aires	1.34265e+07	0.234378	0.653638	0.11198
2	Gran Córdoba	-31.365	-64.225	1	1599	0.381219	0.242404	Cordoba	1.41877e+06	0.236819	0.660851	0.10233
3	Gran Rosario	-32.925	-60.71	0	1304	0.354557	0.241668	Santa Fe	1.21714e+06	0.212762	0.664648	0.12258
4	Gran Mendoza	-32.915	-68.84	1	974	0.365075	0.225724	Mendoza	898926	0.238383	0.650552	0.11106
5	Gran La ...	-34.912	-57.986	1	942	0.252527	0.24454	Buenos Aires	758844	0.222113	0.662808	0.11507
6	Gran San ...	-26.825	-65.218	1	739	0.439469	0.280148	Tucuman	790399	0.264694	0.651432	0.08387
7	Mar del ...	-38.006	-57.578	0	820	0.303776	0.215475	Buenos Aires	579235	0.211696	0.641563	0.14674
8	Gran Santa ...	-31.627	-60.716	1	463	0.3109	0.24556	Santa Fe	458931	0.23823	0.654719	0.10705
9	Gran Salta	-24.806	-65.421	1	449	0.48854	0.246249	Salta	538727	0.277913	0.643901	0.07818
10	Gran San ...	-31.539	-68.545	1	416	0.512316	0.230518	San Juan	421143	0.26709	0.635979	0.09693
11	Gran ...	-27.458	-58.987	1	407	0.506737	0.264614	Chaco	368764	0.260777	0.663365	0.07585
12	Santiago De...	-27.784	-64.26	1	319	0.397833	0.2601	Santiago de...	348651	0.277223	0.64568	0.07709
13	Gran ...	-27.486	-58.805	1	297	0.408022	0.284027	Corrientes	338641	0.257816	0.66735	0.07483
14	Bahía Blanca	-38.723	-62.262	0	343	0.227252	0.171884	Buenos Aires	275420	0.202563	0.661644	0.13579
15	Neuquén - ...	-38.945	-68.078	1	393	0.362603	0.236834	Neuquen	329502	0.249322	0.678305	0.07237
16	Gran Paraná	-31.752	-60.505	1	313	0.302394	0.222582	Entre Rios	255513	0.237585	0.661508	0.10096
17	Gran Posadas	-27.409	-55.908	1	312	0.432229	0.247952	Misiones	313712	0.284293	0.645241	0.07046
18	Gran San ...	-24.212	-65.278	1	283	0.386536	0.218763	Jujuy	301536	0.267922	0.654589	0.07748
19	Formosa	-26.174	-58.189	1	221	0.518205	0.285748	Formosa	214828	0.282212	0.649841	0.06794
20	Gran Río ...	-33.121	-64.347	0	178	0.388003	0.198681	Cordoba	157470	0.223566	0.652086	0.12434
21	Gran San ...	-30.461	-65.761	1	176	0.317361	0.20501	Cordoba	104100	0.270047	0.650007	0.07706

Format

Resize

☒ Background color

☒ Column min/max

Save and Close

Close

# Desarrollo: Obtención de la Información

Con esta nueva base de datos fue mucho más sencillo utilizar la api de google maps. También sirvió para expandir notablemente la cantidad de sitios a considerar.

Debido a esto último, se crearon algunos diccionarios auxiliares para optimizar el proceso de búsqueda.



```
10 for aglomerado in aglomerados:
11     if aglomerado["ES_CAPITAL"] == 0:
12         capital = capitales[aglomerado["PROVINCIA"]].replace(" ", "_")
13         lat_lon = str(aglomerado["LAT"]) + "," + str(aglomerado["LON"])
14         url = "https://maps.googleapis.com/maps/api/distancematrix/
            json?origins=" + lat_lon + "&destinations=" + capital + "+"
            + aglomerado["PROVINCIA"].replace(" ", "_") + "+Argentina"
            + "&region=.ar" + "&key=" + API_key
15         dato_de_google = urllib.request.urlopen(url).read()
16         datos_json = json.loads(dato_de_google)
17         data = datos_json["rows"][0]["elements"][0]
18         if data["status"] == "OK" :
19             aglomerado["DIST_CAP_PROV"] = data["distance"]
20             aglomerado["TIEMPO_CAP_PROV"] = data["duration"]
```

# Desarrollo: Análisis y visualización

```
###
data_cols = ['IVS_MEDIA', 'IVS_DESVIO', 'log_pob',
             'prop_infantes', 'prop_mayores',
             'prop_mujeres', 'TIEMPO_CAP_PROV']
df = df_completo[data_cols]
Xorig = df.values
scaler = StandardScaler()
X = scaler.fit_transform(Xorig)
pca = PCA(7)
pca.fit(X)
pcaX = pca.fit_transform(X)
```

- + agregamos log(poblacion)
- + seleccionamos features a usar
- + escalamos datos
- + realizamos un PCA


# Desarrollo: Análisis y visualización



# Desarrollo: Análisis y visualización

Vemos cómo se componen las primeras componentes principales.


```
In [182]: d
Out[182]:
{0: 'IVS_MEDIA',
 1: 'IVS_DESVIO',
 2: 'log_pob',
 3: 'prop_infantes',
 4: 'prop_mayores',
 5: 'prop_mujeres',
 6: 'TIEMPO_CAP_PROV'}
```





# Desarrollo: Análisis y visualización

## Gaussian Mixture Model



Generalización de K-Means.

Es una familia de modelos de aprendizaje no supervisado basados en sumas de normales, o sea de gaussianas. Tiene varios parámetros que dan lugar a distintos clasificadores.

Tiene que ver con la forma y cantidad de las gaussianas.

# Desarrollo: Análisis y visualización

## Gaussian Mixture Model

```
from sklearn import mixture

#%%
#GMM Gaussian Mixture Model
lowest_bic = np.infty
bic = []
n_components_range = range(1, 12)
cv_types = ['spherical', 'tied', 'diag', 'full']
for cv_type in cv_types:
    for n_components in n_components_range:

        gmm = mixture.GaussianMixture(n_components=n_components,
                                       covariance_type=cv_type)


        gmm.fit(X)
        bic.append(gmm.bic(X))
        if bic[-1] < lowest_bic:
            lowest_bic = bic[-1]
            best_gmm = gmm

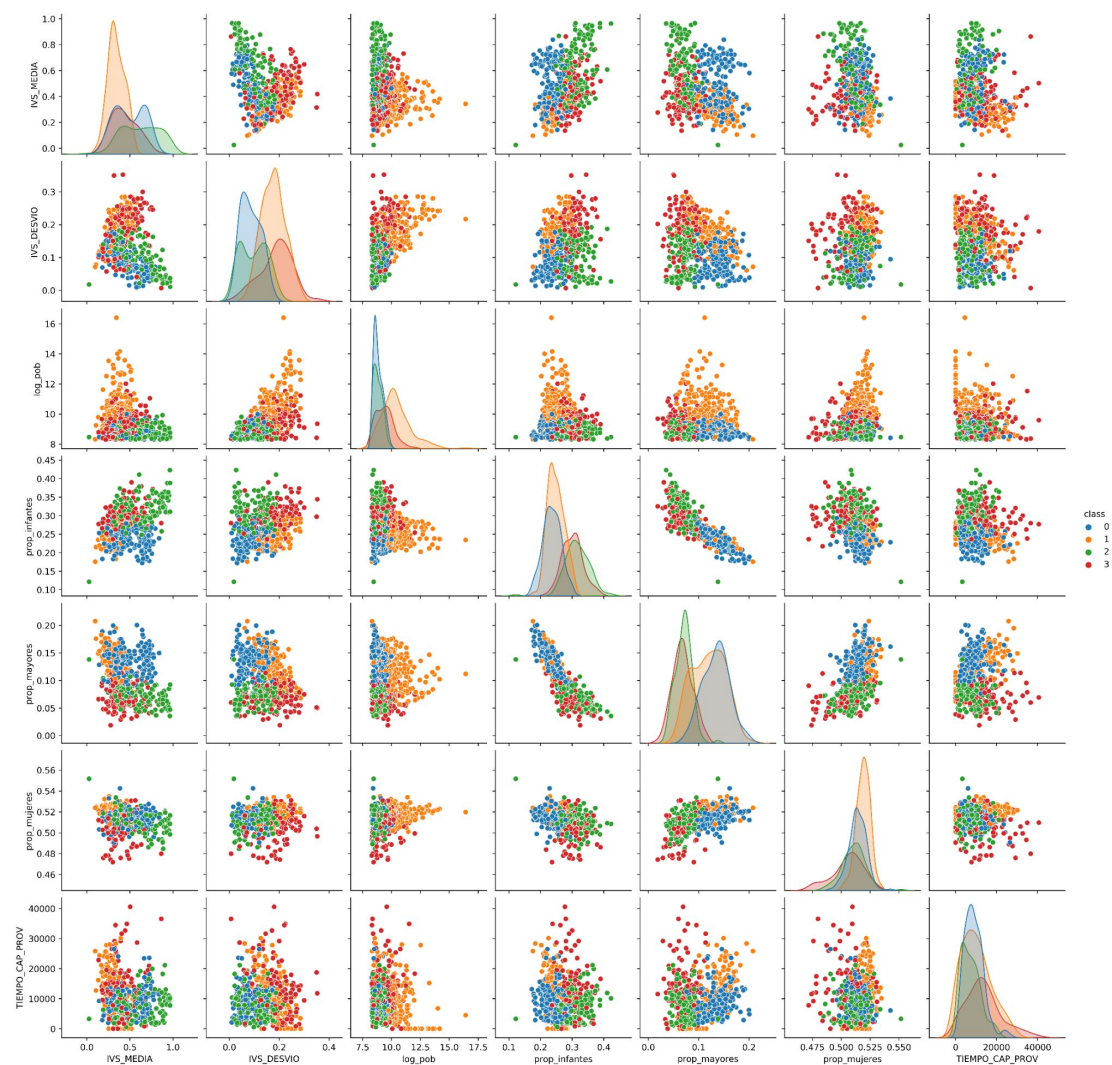
bic = np.array(bic)
```

Probamos con distintas combinaciones de cantidad de gaussianas y de formas de las mismas, seleccionando el modelo con mejor bic.

# Desarrollo: Análisis y visualización

## Gaussian Mixture Model







- La clase naranja es la de aglomerados con más población. Ahí hay menor IVS.
- Las clases verde y azul tienen menos población, y mayor IVS media, con bajos desvíos.
- La proporción de mujeres es alta en lugares de mayor población.
- Las clases roja y verde tienen baja proporción de adultos mayores, las clases azul y naranja tienen alta proporción.
- Algo obvio: Las capitales tienen alta población. Las proporciones de infantes y de mayores tienen una relación inversa.

# Dónde se ubican las clases

## Proyección a 2D componentes principales





# Conclusiones

# Algunas Cosas Observables

Pudimos ver, después de analizar varias combinaciones de variables, que parece haber alguna correlación clara entre lo alejada que una población esté de su capital y del IVS, aún con el modelo más simple.

Existen outliers, por supuesto, pero pareciera notarse un patrón.






# Algunas Cosas Observables


En el ejemplo, sólo utilizamos la distancia a la capital como variable a tomar en cuenta y parecieran haberse formado 4 grupos bastante definidos:

- Naranja: aglomerados grandes con mucha población.
- Azul: eje Santa Fé - Córdoba
- Zonas más extremas N y S del país (verde principalmente al norte).



# Algunas Cosas Observables



Otro experimento  
considerando más  
features, en el que nos  
dieron 8 clases.



# Algunas Cosas Observables


Otro caso interesante fue el que nos dio considerando la proporción de gente que no asistió a la escuela.

Parecen formarse 3 grupos aún más definidos en las regiones del interior.



## Ideas y Casos Interesantes

Es interesante notar cómo muchos de los lugares que parecen estar mejor en las zonas periféricas van de la mano con los sitios por donde pasan las rutas nacionales (las líneas gruesas a la izquierda).



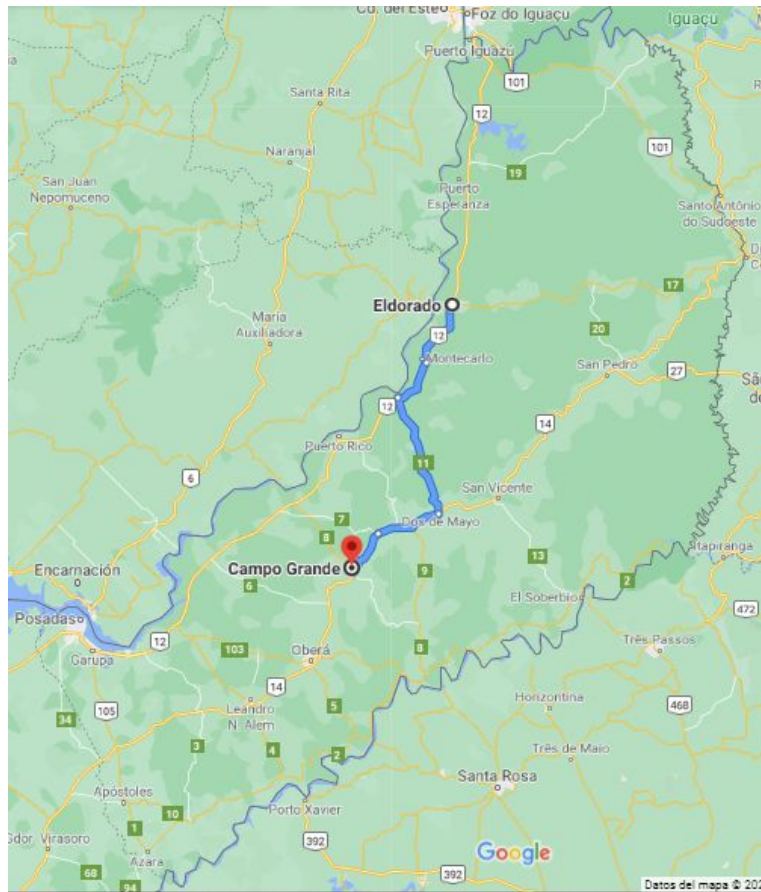
# Ideas y Casos Interesantes

Entre las cosas que se pudieron hacer con los datos iniciales, fue un cálculo muy sencillo para ver cuál sería una capital “ideal”.

La definición utilizada fue que la ciudad elegida debía ser la que esté más cerca de todas las otras en promedio.

De las 23 provincias, 7 de ellas tienen una capital que cumple con esta condición.

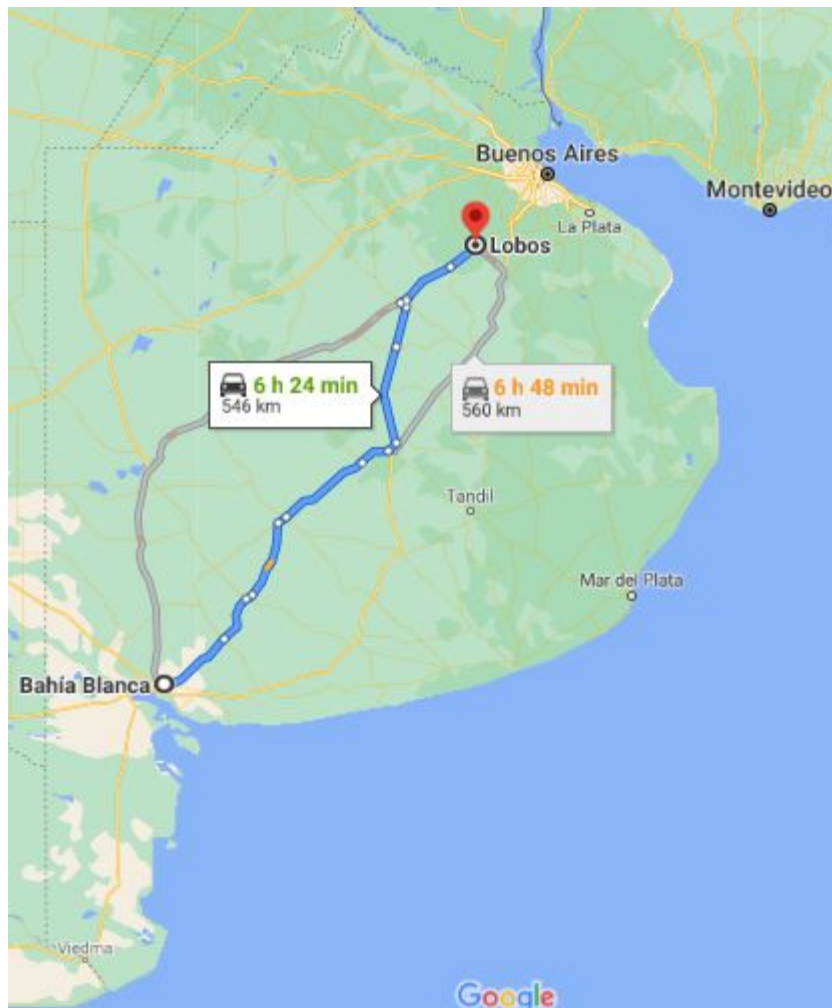
Y de las 16 restantes, hay 5 de las cuales la ciudad que se encontró está al menos un 40% más cerca al resto que la capital actual.



## Ideas y Casos Interesantes

Es importante recalcar el hecho de que algunas de las potenciales capitales usando nuestro criterio pueden no ser ideales desde un punto de vista práctico.

Además hay un caso notable en el cual, por las particularidades demográficas de la región, nuestra forma de analizarlo pierde un poco el sentido: Buenos Aires



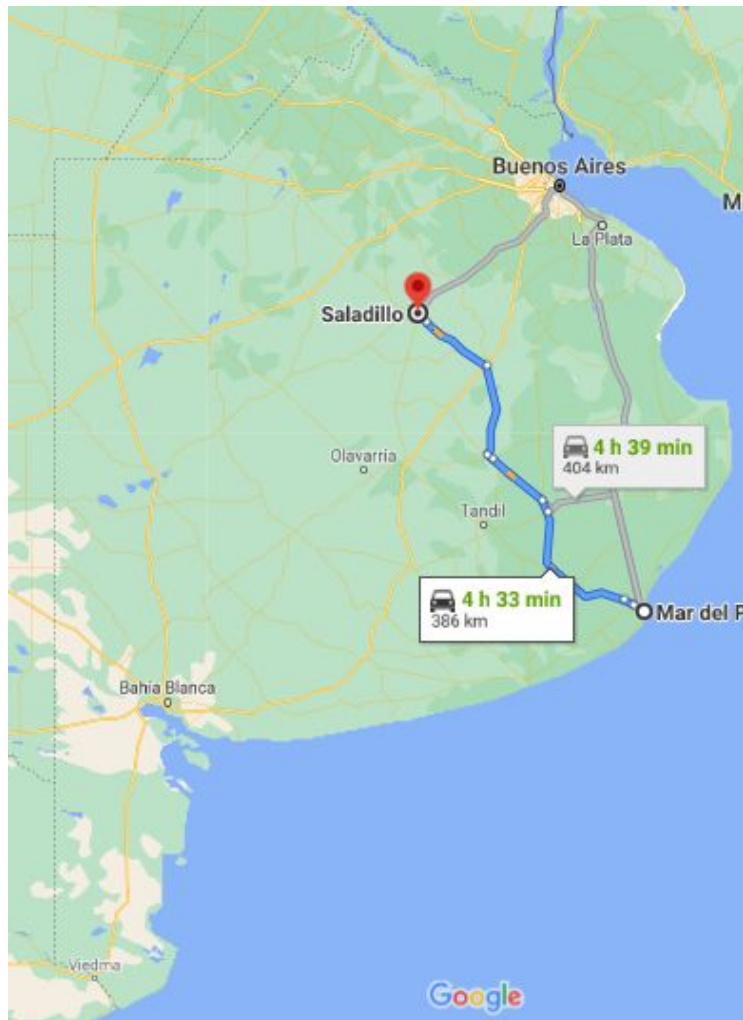


## Ideas y Casos Interesantes

En el caso particular, se debe a la inmensa cantidad de municipios en el conurbano.

Si tomamos al conurbano como una sola ciudad, la situación cambia un poco.

Hay que tener en cuenta que sigue habiendo más densidad poblacional en el norte.





**FIN**

## Fuentes:

- INDEC - <https://www.indec.gob.ar/>
- Datos del INDEC condensados - <https://dump.jazzido.com/CNPHV2010-RADIO/>
- Fundación Bunge y Born - <https://www.fundacionbyb.org/vulnerabilidad-sanitaria>
- Mapas - <https://mapamundi.online/>
- Mapas - <https://lageografiaweb.blogspot.com/>
- Información General - <https://es.wikipedia.org>